PROGRAMACIÓN AVANZADA
ING. CIVIL PLAN COMÚN – SEDE TEMUCO

"ANÁLISIS DE LA SISMICIDAD EN CHILE (2000-2024) A PARTIR DEL CATÁLOGO DEL USGS"

Proyecto Final Integrador – Avance 2

Limpieza, tratamiento de nulos y transformación de datos

N° Grupo	:	5
Integrantes	:	Benjamin Agurto
		Maximiliano Segovia
		Cristóbal Fernández
Sección	:	1 y 2
Docente	:	Prof. Alex
Fecha	:	02/11/2026
Repositorio	:	https://github.com/YoungTvber/sismos-chile
Nota	:	

INFORME N°2

Características generales

Este informe corresponde al segundo avance del Proyecto Final Integrador. Partimos del conjunto de sismos que cargamos en el avance anterior y construimos un proceso reproducible que revisa la calidad de los datos, los limpia, trata los valores nulos, crea variables nuevas, valida el resultado y lo exporta a un archivo procesado. El archivo original se conserva sin cambios en *datos/originales/*. Todos los resultados que se muestran salen de ejecutar *python main.py* sobre los datos reales.

1. Recordatorio del proyecto

Pregunta principal. ¿La frecuencia anual de los sismos de magnitud 4,5 o superior en Chile aumenta o disminuye entre 2000 y 2024, y cambia según la magnitud?

Fuente de los datos. Catálogo de sismos del Servicio Geológico de Estados Unidos (USGS, ComCat), en formato CSV, consultado el 25/10/2026. Tras filtrar por Chile, el conjunto original tiene 6.460 registros y 22 columnas, entre el 01/01/2000 y el 05/01/2024. Es de uso libre citando al USGS. El detalle de la fuente está en el informe del avance 1 y en *datos/README.md*.

2. Diagnóstico de calidad

Antes de modificar algo, analizamos el conjunto original con la función *diagnosticar_calidad*, del módulo *validaciones.py*. Los indicadores son los siguientes:

Indicador	Resultado
Filas y columnas	6.460 filas y 22 columnas
Tipos de datos	12 columnas float64 y 10 de texto (str); la fecha llega como texto
Valores nulos	20.416 celdas nulas, repartidas en 8 columnas
Filas duplicadas	0 (tampoco hay duplicados si se ignora el id)
Identificadores repetidos	0
Valores fuera de rango	0 en magnitud (4,5 a 10), profundidad (0 a 700 km) y coordenadas; 446 eventos fuera del área de estudio
Categorías inconsistentes	0 (los códigos no difieren en mayúsculas ni espacios)
Espacios sobrantes en el texto	0

La tabla de nulos por columna, con su porcentaje, es la siguiente:

Variable (nombre original)	Nulos	Porcentaje
horizontalError	4.050	62,7 %
magError	4.049	62,7 %
dmin	3.796	58,8 %
nst	2.671	41,3 %
depthError	2.633	40,8 %
magNst	1.532	23,7 %
rms	980	15,2 %
gap	705	10,9 %

Interpretación. Las variables que necesitamos para responder la pregunta (fecha, latitud, longitud, profundidad y magnitud) están completas. El principal problema de calidad son los nulos en las columnas de precisión y de calidad de la medición, que llegan hasta 63 % de faltantes. Detectamos además 446 eventos de la dorsal oceánica West Chile Rise, que ocurren en mar abierto y no corresponden a la zona de subducción que queremos estudiar, y la fecha guardada como texto. No encontramos duplicados, identificadores repetidos ni valores imposibles.

```
$ python main.py
1. CARGA
Carga realizada correctamente.

2. DIAGNÓSTICO DEL CONJUNTO ORIGINAL
Filas: 6460 | Columnas: 22

Valores nulos (columnas con nulos):
                 nulos  porcentaje
horizontalError   4050        62.7
magError          4049        62.7
dmin              3796        58.8
nst               2671        41.3
depthError        2633        40.8
magNst            1532        23.7
rms                980        15.2
gap                705        10.9

Total de valores nulos: 20416
Filas duplicadas: 0
Identificadores repetidos: 0
Valores fuera de rango: {'mag': 0, 'depth': 0, 'latitude': 0, 'longitude': 0}
Eventos fuera del área de estudio (West Chile Rise): 446
Categorías inconsistentes: 0
```

3. Limpieza realizada

La limpieza está en *limpieza.py* y cada acción queda registrada en *reportes/registro_limpieza.txt*. Aplicamos lo siguiente, indicando también lo que se revisó y no necesitó cambios:

Problema	Acción aplicada	Cantidad	Justificación
Nombres de columnas en inglés o abreviados	Renombrar a español descriptivo (snake_case)	22 columnas	Mayor claridad y coherencia con el diccionario de datos
Espacios sobrantes y mayúsculas en texto	strip() y minúsculas en columnas de código	0 celdas	Se revisó y no había casos; la función queda para datos futuros
Filas duplicadas	drop_duplicates()	0 filas	No se encontraron registros idénticos
Identificadores repetidos	Revisión de id_evento	0	Cada evento tiene un identificador único

Problema	Acción aplicada	Cantidad	Justificación
Eventos de West Chile Rise	Eliminar los registros	446 filas (6,9 %)	Dorsal oceánica en mar abierto, otro ambiente tectónico que el de la zona de subducción estudiada
Metadatos sin uso en el análisis	Eliminar actualizado, fuente_ubicacion y fuente_magnitud	3 columnas	No aportan a la pregunta sobre frecuencia anual por magnitud
Valores fuera de rango	Sin cambios	0	Magnitud, profundidad y coordenadas están dentro de lo posible. Los 4 registros con profundidad 0 km se mantienen por estar en rango
Isla de Pascua (Hanga Roa)	Conservar	26 filas	Es territorio chileno; no se confunde con la dorsal

Los únicos registros eliminados fueron los 446 de West Chile Rise. Todos los demás cambios afectan a columnas o al formato, no a los sismos.

```
3. LIMPIEZA
- Columnas renombradas: 22 (nombres en español y sin abreviaturas).
- Texto: espacios y mayúsculas corregidos en 0 celdas.
- Duplicados: 0 filas idénticas eliminadas.
- Identificadores repetidos: 0.
- Fuera del área de estudio: 446 registros de 'West Chile Rise' eliminados (dorsal oceánica en mar abierto,
  distinta a la zona de subducción bajo estudio).
- Columnas eliminadas por no aportar al análisis: ['actualizado', 'fuente_ubicacion', 'fuente_magnitud'].
```

4. Tratamiento de nulos

No usamos una sola estrategia para todo. Primero separamos las columnas que sirven para el análisis de las que no, y después decidimos caso por caso. En ningún caso reemplazamos nulos por cero.

Variable	Nulos iniciales	Estrategia	Justificación	Nulos finales
dist_min_estacion (dmin)	3.796	Eliminar la columna	Más de la mitad de los valores faltan y no se usa en el análisis	no aplica
error_horizontal_km	4.050	Eliminar la columna	Más de la mitad faltan; es una medida de precisión sin uso en el análisis	no aplica
error_magnitud	4.049	Eliminar la columna	Más de la mitad faltan; es una medida de precisión sin uso en el análisis	no aplica
error_profundidad_km	2.633	Eliminar la columna	40 % de faltantes y es una medida de precisión que no se usa	no aplica
n_estaciones	2.671	Mantener el nulo	El nulo significa que la red no informó el dato; imputarlo inventaría información	2.451
brecha_azimutal	705	Mantener el nulo	Igual que la anterior	653
rms	980	Mantener el nulo	Igual que la anterior	972
n_estaciones_magnitud	1.532	Mantener el nulo	Igual que la anterior	1.417

Los nulos finales son menores que los iniciales solo porque al eliminar los 446 registros de West Chile Rise también se fueron los nulos que tenían esas filas. No descartamos la categoría “desconocido” por capricho: no hay variables categóricas con nulos, así que no hacía falta. Tampoco imputamos con media o mediana, porque son medidas de calidad que dependen de cada estación y un promedio no representaría ningún sismo real. Las columnas que usaremos en el análisis (fecha, ubicación, profundidad y magnitud) siguen con cero nulos.

5. Transformaciones aplicadas

Las transformaciones están en *transformaciones.py*. Aplicamos nueve, más de las tres mínimas:

Variable original	Transformación	Resultado	Tipo final
time → fecha_hora	pd.to_datetime(..., utc=True)	2000-01-01 04:30:10+00:00	datetime64[ns, UTC]
nst, magNst	astype('Int64'), enteros con nulos permitidos	12 y 15 en lugar de 12.0 y 15.0	Int64
magType, status, type, net	astype('category')	mb, reviewed, earthquake, us	category
fecha_hora	Extraer año con .dt.year	anio = 2000	int
fecha_hora	Extraer mes con .dt.month	mes = 1	int
anio	Comparar con 2024 (año incompleto)	anio_completo = True; False para 3 sismos	bool
magnitud	pd.cut en rangos de magnitud	4.5-4.9, 5.0-5.9, 6.0-6.9, 7.0 o más	category
profundidad_km	pd.cut: superficial (< 70 km), intermedia (70 a 300 km) y profunda (300 km o más)	clase_profundidad = intermedia (105 km)	category
latitud, longitud	pd.cut por latitud; insular para Rapa Nui	zona = norte, centro, sur, austral o insular	category

Cuatro de las columnas nuevas (rango de magnitud, clase de profundidad, zona y bandera de año completo) responden directamente a la pregunta: permiten contar sismos por año y comparar su frecuencia según la magnitud. La zona se asigna por latitud (norte desde -30°, centro entre -30° y -37°, sur entre -37° y -43° y austral al sur de -43°), por lo que es una aproximación y no una división administrativa.

Diccionario del dataset limpio

Variable	Descripción	Tipo final	Unidad o formato	Valores permitidos	¿Permite nulos?	Ejemplo
id_evento	Identificador único del evento	str	Sin unidad	Texto único	No	usp0009kk5
fecha_hora	Fecha y hora de origen	datetime64[ns, UTC]	AAAA-MM-DD hh:mm:ss (UTC)	2000 a enero de 2024	No	2000-01-01 04:30:10+00:00
latitud	Latitud del epicentro	float64	Grados decimales	-56 a -17 (observado: -52,94 a -18,25)	No	-26.012
longitud	Longitud del epicentro	float64	Grados decimales	-113 a -66 (observado: -112,29 a -66,94)	No	-68.803
profundidad_km	Profundidad del foco	float64	km	0 a 700 (observado: 0 a 241,9)	No	105.0
magnitud	Magnitud del sismo	float64	Adimensional	4,5 a 10 (observado: 4,5 a 8,8)	No	4.5
tipo_magnitud	Escala de la magnitud	category	Código	mb, mwr, mww, mwc, mwb, ml, md, m, ms, mw	No	mb
lugar	Descripción textual del lugar	str	Texto libre	Texto no vacío	No	130 km ENE of Diego de Almagro, Chile
estado	Estado de revisión	category	Código	reviewed, automatic	No	reviewed
tipo_evento	Tipo de evento	category	Código	earthquake	No	earthquake
red	Red que aportó el evento	category	Código	us, gcmt, iscgem, official	No	us
n_estaciones	Estaciones que reportaron ondas P y S	Int64	Cantidad	Enteros positivos	Sí (2.451)	12
brecha_azimutal	Mayor vacío azimutal entre estaciones	float64	Grados	0 a 360	Sí (653)	245.1
rms	Residuo cuadrático medio	float64	Segundos	Mayor o igual a 0	Sí (972)	0.91
n_estaciones_magnitud	Estaciones usadas para la magnitud	Int64	Cantidad	Enteros positivos	Sí (1.417)	15
anio	Año del sismo	int	AAAA	2000 a 2024	No	2000
mes	Mes del sismo	int	1 a 12	1 a 12	No	1
anio_completo	Indica si el año tiene datos completos	bool	Verdadero o falso	False solo en 2024	No	True
rango_magnitud	Rango de magnitud	category	Texto	4.5-4.9, 5.0-5.9, 6.0-6.9, 7.0 o más	No	4.5-4.9
clase_profundidad	Clase según profundidad	category	Texto	superficial, intermedia, profunda	No	intermedia
zona	Zona del país según la latitud	category	Texto	norte, centro, sur, austral, insular	No	norte

6. Modularización del código

Separamos el código en módulos con una responsabilidad cada uno y dejamos en *main.py* solo el orden de ejecución. Todas las rutas son relativas a la raíz del proyecto y el programa se ejecuta con *python main.py*.



Figura 1. Pipeline implementado, con el módulo responsable de cada etapa.

Archivo	Responsabilidad	Funciones principales
carga.py	Lectura y exportación del conjunto	cargar_datos, inspeccionar_datos, exportar_datos
limpieza.py	Nombres, texto, duplicados, área de estudio y nulos	normalizar_columnas, limpiar_texto, eliminar_duplicados, filtrar_area_estudio, tratar_nulos
transformaciones.py	Conversión de tipos y creación de variables	convertir_fecha, convertir_tipos, crear_variables
validaciones.py	Diagnóstico y comprobación de columnas, tipos y rangos	diagnosticar_calidad, validar_dataset, comparar_antes_despues
main.py	Ejecución ordenada del pipeline	main

```
datos/originales/   conjunto original (no se modifica)
datos/procesados/    dataset_limpio.csv
reportes/            avance_1.pdf, avance_2.pdf, registro_limpieza.txt
src/                 carga.py, limpieza.py, transformaciones.py, validaciones.py
main.py  README.md  requirements.txt
```

7. Comparación antes y después

Indicador	Antes	Después
Filas	6.460	6.014
Columnas	22	21
Valores nulos	20.416	5.493
Filas duplicadas	0	0
Valores fuera de rango	446	0
Variables transformadas	0	7
Variables nuevas	0	6

Las 21 columnas finales salen de restar siete columnas eliminadas a las 22 originales y sumar seis variables nuevas. Los 5.493 nulos que quedan están en las cuatro columnas de calidad que se conservaron. Los "valores fuera de rango" del conjunto original son los 446 eventos fuera del área de estudio. Las siete variables transformadas son fecha_hora, n_estaciones, n_estaciones_magnitud, tipo_magnitud, estado, tipo_evento y red.

8. Evidencias de ejecución

Salida real de *python main.py* en la etapa de diagnóstico, seguida de la validación del resultado y de una muestra del archivo final.

```
6. VALIDACIÓN
Columnas: OK
Tipos de datos: OK
Rangos: OK
Identificadores únicos: OK
Validación completa: sin problemas.
7. EXPORTACIÓN
Archivo generado: datos/procesados/dataset_limpio.csv
COMPARACIÓN ANTES Y DESPUÉS
Indicador                    Antes   Después
Filas                         6460      6014
Columnas                        22        21
Valores nulos                20416      5493
Filas duplicadas                 0         0
Valores fuera de rango         446         0
Variables transformadas          0         7
Variables nuevas                 0         6
Registro de la limpieza guardado en reportes/registro_limpieza.txt
```

```
df = pd.read_csv('datos/procesados/dataset_limpio.csv')
df[...].head()
                       fecha_hora  magnitud  profundidad_km  anio  mes rango_magnitud clase_profundidad     zona
0  2000-01-01 04:30:10.370000+00:00       4.5           105.0  2000    1        4.5-4.9        intermedia    norte
1  2000-01-06 21:37:49.760000+00:00       4.6           143.2  2000    1        4.5-4.9        intermedia    norte
2  2000-01-08 11:59:21.840000+00:00       6.4            36.0  2000    1        6.0-6.9       superficial    norte
3  2000-01-10 23:34:22.740000+00:00       4.7            33.0  2000    1        4.5-4.9       superficial  austral
4  2000-01-11 13:16:34.420000+00:00       4.5            78.8  2000    1        4.5-4.9        intermedia   centro

df[...].sample(5, random_state=7)
                          fecha_hora  magnitud  profundidad_km  anio  mes rango_magnitud clase_profundidad    zona
4385  2015-10-26 14:26:21.310000+00:00       4.5           10.00  2015   10        4.5-4.9       superficial  centro
4282  2015-09-21 15:37:08.040000+00:00       5.4           25.57  2015    9        5.0-5.9       superficial  centro
1591  2010-02-27 15:22:53.640000+00:00       5.0           35.00  2010    2        5.0-5.9       superficial  centro
3063         2012-05-13 12:42:49+00:00       4.8           12.70  2012    5        4.5-4.9       superficial  centro
1661  2010-02-27 22:05:55.910000+00:00       4.9           35.00  2010    2        4.5-4.9       superficial  centro
```

El archivo generado es *datos/procesados/dataset_limpio.csv*, con 6.014 filas y 21 columnas. El archivo original sigue en *datos/originales/*, con 6.460 filas y 22 columnas.

9. Conclusión del avance

El proceso permitió pasar del archivo original del USGS a un conjunto limpio de 6.014 registros y 21 columnas, listo para el análisis. Los problemas corregidos fueron los nombres poco descriptivos, las fechas guardadas como texto, los conteos almacenados como decimales y los eventos de la dorsal oceánica West Chile Rise, que no corresponden a la zona de subducción que queremos estudiar.

Eliminamos 446 registros, todos de esa dorsal, y siete columnas: cuatro de precisión con muchos nulos y tres de metadatos. No imputamos ningún valor: las variables clave no tenían nulos y, en las cuatro columnas de calidad que conservamos, el nulo significa que la red no informó el dato. Aplicamos conversiones de fecha y de tipos, y creamos seis variables nuevas: año, mes, bandera de año completo, rango de magnitud, clase de profundidad y zona.

Quedan pendientes tres cosas: las diez escalas de magnitud siguen mezcladas, las réplicas de 2010 deberán tratarse con cuidado en el análisis y el año 2024 sigue en el archivo, marcado como incompleto. Con esto, los datos están preparados para calcular la frecuencia anual por rango de magnitud en el siguiente avance.

10. Enlace al repositorio actualizado

Repositorio: **https://github.com/YoungTvber/sismos-chile**. Los commits de este avance son los siguientes:

Commit	Autor
Reorganiza datos en carpetas originales y procesados	Benjamin Agurto
Agrega diagnóstico inicial de calidad y validaciones	Maximiliano Segovia
Implementa limpieza y tratamiento de valores nulos	Cristóbal Fernández
Incorpora transformaciones de fechas y variables	Benjamin Agurto
Ejecuta el pipeline completo desde main.py	Maximiliano Segovia
Exporta dataset limpio y registro de la limpieza	Cristóbal Fernández
Actualiza informe del avance 2	Benjamin Agurto

11. Referencias

Centro Sismológico Nacional, Universidad de Chile. (s. f.). *Centro Sismológico Nacional*. https://www.csn.uchile.cl

nadeeshafdo. (s. f.). *SeismicDataWorldwide* [Repositorio de datos]. GitHub. https://github.com/nadeeshafdo/SeismicDataWorldwide

The pandas development team. (s. f.). *pandas documentation*. https://pandas.pydata.org/docs/

U.S. Geological Survey. (s. f.). *FDSN Event Web Service: ANSS ComCat earthquake catalog*. https://earthquake.usgs.gov/fdsnws/event/1/